



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Desenvolvimento de modelos preditivos com base em RNN

Luís Ricardo Silva Inácio

Número de Aluno: 129074

Mestrado em Inteligência Artificial

Orientador: Tozé Brito, Phd

Coorientador: Rui Brito, Phd

Outubro, 2024



TECNOLOGIAS
E ARQUITETURA

Departamento de Ciências e Tecnologias da Informação

Desenvolvimento de modelos preditivos com base em RNN

Luís Ricardo Silva Inácio

Número de Aluno: 129074

Orientador: Tozé Brito, Phd

Coorientador: Rui Brito, Phd

Outubro, 2024

Direitos de cópia ou Copyright

©Copyright: Luís Ricardo Silva Inácio

O Iscte - Instituto Universitário de Lisboa tem o direito, perpétuo e sem limites geográficos, de arquivar e publicitar este trabalho através de exemplares impressos reproduzidos em papel ou de forma digital, ou por qualquer outro meio conhecido ou que venha a ser inventado, de o divulgar através de repositórios científicos e de admitir a sua cópia e distribuição com objetivos educacionais ou de investigação, não comerciais, desde que seja dado crédito ao autor e editor.

Agradecimentos

Gostaria de expressar a minha gratidão a todas as pessoas que me apoiaram durante a realização deste trabalho...

Resumo

Texto do resumo em português.

Palavras-chave: palavra-chave1, palavra-chave2, palavra-chave3.

Abstract

Texto do resumo em inglês.

Keywords: keyword1, keyword2, keyword3.

Índice

Agradecimentos	ii
Resumo	iii
Abstract	iv
Lista de Abreviaturas e Siglas	viii
1 Introdução	1
2 Revisão de Literatura	2
3 Metodologia	3
4 Resultados	4
5 Conclusão	5
Referências Bibliográficas	5
A Anexo A	7

Lista de Figuras

Lista de Tabelas

Lista de Abreviaturas e Siglas

Sigla	Descrição
API	Application Programming Interface
BI	Business Intelligence
KPI	Key Performance Indicator

1. Introdução

A inteligência artificial tem evoluído significativamente nas últimas décadas, com avanços em redes neurais profundas sendo especialmente notáveis. O livro seminal de Goodfellow, Bengio, and Courville (2016) destaca como o deep learning transformou o campo, permitindo o desenvolvimento de modelos complexos para problemas de visão computacional, linguagem natural e mais. Além disso, Taylor (2015) enfatiza que a simplicidade de certas abordagens pode ser essencial para iniciantes entenderem os fundamentos da aprendizagem automática.

Os desafios associados à implementação e otimização de redes neurais foram explorados em várias pesquisas. Por exemplo, Rao (2019) argumenta que os principais desafios incluem o ajuste de hiperparâmetros e a escalabilidade dos modelos.

2. Revisão de Literatura

A literatura recente tem investigado estratégias para otimizar redes neurais e melhorar a eficiência dos modelos. Smith, Johnson, and Taylor (2021) analisaram técnicas avançadas de otimização que têm um impacto direto no desempenho de redes neurais em tarefas críticas. Da mesma forma, Brown (2020) exploraram o papel da aprendizagem automática na análise preditiva, destacando a importância do machine learning para setores como saúde e finanças.

Um avanço importante foi a introdução de redes convolucionais para classificação de imagens por Krizhevsky, Sutskever, and Hinton (2012), que revolucionou a área com a sua abordagem baseada no conjunto de dados ImageNet. Estudos subsequentes, como os apresentados em “Recent advances in RNNs” (2021), detalham os avanços em redes recorrentes, ampliando sua aplicabilidade em processamento de séries temporais e geração de texto.

Contribuições teóricas também foram fundamentais. O livro Press (2018) fornece uma base sólida sobre os princípios de aprendizagem profunda, enquanto contributors (2024) oferece uma visão geral acessível das redes neurais recorrentes.

3. Metodologia

A metodologia deste estudo foi baseada em abordagens sugeridas por Smith et al. (2021), que enfatizam a utilização de técnicas otimizadas para treinar redes profundas. Além disso, os parâmetros do modelo foram ajustados com base nos princípios descritos por Rao (2019), garantindo um equilíbrio entre desempenho e complexidade computacional.

O framework experimental foi inspirado nas estratégias utilizadas em Krizhevsky et al. (2012), adaptando redes convolucionais para novos conjuntos de dados. Também foram incorporadas técnicas de análise preditiva baseadas nas metodologias descritas por Brown (2020).

4. Resultados

Os resultados obtidos corroboram os achados de Smith et al. (2021), demonstrando melhorias significativas na eficiência do modelo ao adotar técnicas avançadas de otimização. Adicionalmente, os modelos baseados em redes convolucionais apresentaram precisão semelhante às descritas por Krizhevsky et al. (2012), validando sua robustez em tarefas de classificação de imagens.

Curiosamente, as limitações de redes recorrentes, como discutido por “Recent advances in RNNs” (2021), foram observadas em tarefas de processamento sequencial, reforçando a necessidade de arquiteturas híbridas para superar esses desafios.

5. Conclusão

Com base nas evidências apresentadas, pode-se concluir que a adoção de técnicas modernas de otimização e arquiteturas avançadas de redes neurais desempenha um papel crucial no avanço da inteligência artificial. Conforme discutido em Goodfellow et al. (2016), o futuro do deep learning depende da contínua integração de métodos teóricos e práticos.

Além disso, as contribuições de Rao (2019) e Brown (2020) destacam que uma abordagem multidisciplinar é essencial para enfrentar os desafios associados à escalabilidade e aplicação prática dos modelos. Este trabalho, portanto, reforça a importância da pesquisa colaborativa e interdisciplinar no progresso da inteligência artificial.

Bibliografia

- Brown, P. (2020). Machine learning for predictive analytics. *Data Science Journal*, 12(4), 56–75.
- contributors, W. (2024). *Recurrent neural networks*. (In Wikipedia. Retrieved from https://en.wikipedia.org/wiki/Recurrent_neural_network)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems* (Vol. 25, pp. 1097–1105).
- Press, M. (2018). *Foundations of deep learning*. Author.
- Rao, K. (2019). Challenges in neural networks. *AI Research Journal*, 10(2), 98–110.
- Recent advances in rnns. (2021). *Neural Networks Review*, 5(1), 34–50.
- Smith, J., Johnson, R., & Taylor, K. (2021). Optimization techniques for neural networks. *Journal of Machine Learning Research*, 22(3), 1–20. doi: 10.1234/jmlr.v22i3.5678
- Taylor, K. (2015). Simplifying neural networks for beginners. *Journal of AI*, 8(3), 25–35.

A. Anexo A

Texto fictício para apêndice. Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.